lab-6

January 3, 2024

1 Podejmowanie decyzji

1.1 Wstęp

Celem tego laboratorium jest zapoznanie się z kilkoma metodami wykorzystywanymi do podejmowania decyzji w kontekście, w którym dwa podmioty mają sprzeczne cele, a konkretnie w sytuacji, w której wygrana jednego podmiotu oznacza przegraną drugiego podmiotu. Wykorzystamy do tego grę w kółko i krzyżyk, która posiada bardzo proste zasady. Zaprezentowane metody mają jednak znacznie szersze zastosowanie i mogą być wykorzystywane w szerokim spektrum problemów decyzyjnych.

Zastosowane metody to: * losowe przeszukiwanie przestrzeni decyzji, * heurystyczne przeszukiwanie przestrzeni decyzji, * algorytm minimax, * algorytm alpha-beta, * przeszukiwanie w oparciu o metodę Monte Carlo.

Na końcu laboratorium zrobimy turniej graczy zaimplementowanych z użyciem tych metod i zobaczymy, która metoda razi sobie najlepiej w grze w kółko i krzyżyk.

NIE WYKONANIE TURNIEJU SKUTKUJE OTRZYMANIEM ZERA PUNKTÓW ZA ZADANIE

2 Gra w kółko i krzyżyk

Zaczniemy od implementacji gry w kółko i krzyżyk. Możemy podejść do tego na kilka różnych sposobów. Jednym z najprostszych jest gracz wykonujący losowy ruch i liczący na szczęście. Trochę bardziej skomplikowanym graczem będzie gracz wykorzystujący jakąś heurystykę (można taką znaleźć na Wikipedii), nas będą bardziej interesowali gracze oparci o przeszukiwanie drzewa rozgrywki np. algorytmem minimax czy A*, a w bardziej skomplikowanych problemach znajdują zastosowanie również algorytmy probabilistyczne typu Monte Carlo, a w prostych - klasyczne grafowe przeszukiwanie.

Na początek zaiplemętujemy samą planszę i metody niezbędne do rozgrywki takie jak sprawdzenie, czy ktoś wygrał, wyświetlające stan planszy itd. Poniżej znajduje się implementacja gry, która wyświetla stan gry w fomie tekstowej oraz informuje, kto wygrał grę.

[1]:
```
import numpy as np
from numba import njit
```

[2]:
```
PLAYER_1 = -1
PLAYER_2 = 1
```

```
STRIKE = 3 # same as SIZE, difrent require changes check_for_end() and␣
 ↪consequent
SIZE = 3 # same as STRIKE

KERNEL_D1 = np.eye(STRIKE)
KERNEL_D2 = np.rot90(np.eye(STRIKE))


class TicTacToe:
    def __init__(self, player1, player2, size):
        self.size = size
        self.board = np.zeros((size, size), dtype=int)
        self.player1 = player1
        self.player2 = player2
        self.chars = {0: " ", PLAYER_1: "O", PLAYER_2: "X"}

    def play(self, verbose=True):
        self.print_board(verbose)
        for i in range((self.size*self.size)//2):
            self.player1.move(self.board, PLAYER_1)
            self.print_board(verbose)
            if check_for_end(self.board, PLAYER_1):
                if verbose:
                    print("player 1 wins")
                return "win"
            self.player2.move(self.board, PLAYER_2)
            self.print_board(verbose)
            if check_for_end(self.board, PLAYER_2):
                if verbose:
                    print("player 2 wins")
                return "loss"

        if (self.size % 2) == 1:
            self.player1.move(self.board, PLAYER_1)
            self.print_board(verbose)
            if check_for_end(self.board, PLAYER_1):
                if verbose:
                    print("player 1 wins")
                return "win"
            else:
                if verbose:
                    print("draw")
                return "draw"
        else:
            if verbose:
                    print("draw")
            return "draw"
```

```
    def print_board(self, verbose):
        if not verbose:
            return
        str_line = "---------------"
        print("\n" + str_line)
        for row in self.board:
            for cell in row:
                symbol = self.chars[cell]
                print(f"| {symbol} |", end="")
            print("\n" + str_line)

@njit()
def check_for_end(board, player):
    return (
        check_rows(board, player)
        or check_cols(board, player)
        or check_diagonals(board, player)
    )

@njit()
def check_rows(board, player):
    conv = board.sum(axis=0)
    return (np.max(conv * player) )>=STRIKE

@njit()
def check_cols(board, player):
    conv = board.sum(axis=1)
    return (np.max(conv * player))>=STRIKE

@njit()
def check_diagonals(board, player):
    conv = np.multiply(board,KERNEL_D1).sum()
    conv2 = np.multiply(board, KERNEL_D2).sum()
    return (conv* player)>=STRIKE or (conv2* player) >=STRIKE

@njit()
def can_make_move( board, row, col):
    return board[row][col] == 0

@njit()
def get_possible_moves( board):
    res = []
    for j, row in enumerate(board):
        for i, cel in enumerate(row):
            if can_make_move(board, j, i):
```

```
                res.append((j, i))

    return res
```

2.1 Interfejs gracza

Skoro mamy już zdefiniowaną grę to teraz potrzebny jest nam gracz. Poniżej zdefiniowany jest interface PlayerInreface. Należy go wykorzystywać implementując swoich graczy. Interfejs ma metodę `move`, która reprezentuje pojedynczy ruch gracza a także metodę `name`, która zwraca nazwę zaimplementowanego algorytmu.

[3]:
```
from abc import ABC, abstractmethod


class PlayerInterface(ABC):
    @abstractmethod
    def move(self, board, player):
        pass

    @property
    def name(self):
        return type(self).__name__
```

Zobaczmy, jak wyglądałby prawdopodobnie najprostszy gracz do zaimplementowania, a więc gracz losowy. Wybiera on losowo wiersz i kolumnę, a następnie sprawdza, czy pole jest puste. Jeżeli tak, to stawia tam swój znak.

[4]:
```
import random


class RandomPlayer(PlayerInterface):
    def move(self, board, player):
        while True:
            row, col = random.choice(get_possible_moves(board))
            board[row][col] = player
            return
```

Sprawdźmy, czy wszystko działa.

[5]:
```
game = TicTacToe(RandomPlayer(), RandomPlayer(),SIZE)
game.play()
```

```
---------------
|   ||   ||   |
---------------
|   ||   ||   |
---------------
```

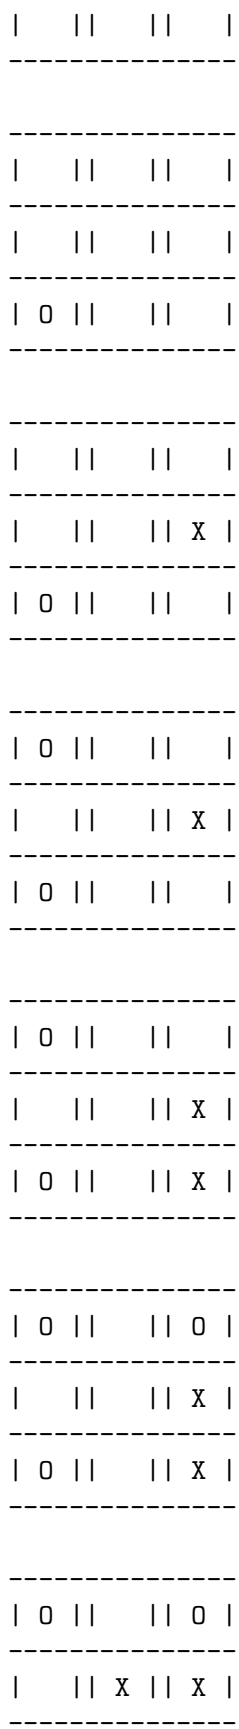

```
| O ||   || X |
---------------

---------------
| O ||   || O |
---------------
| O || X || X |
---------------
| O ||   || X |
---------------
player 1 wins
```

[5]: 'win'

Napiszemy teraz kilku kolejnych graczy, podejmujących decyzje nieco inteligentniej, a na koniec zrobimy mały turniej i sprawdzimy, który jest najlepszy.

3 Podejmowanie decyzji oparte o heurystykę

W każdym nowym problemie warto sprawdzić proste podejście heurystyczne, wykorzystujące elementarną wiedzę o problemie. Sama gra w kółko i krzyżyk, jak wiadomo, nie jest zbyt skomplikowana. Jest w niej najwyżej 9 możliwych ruchów, mniej niż $3^9 - 1$ możliwych końcowych stanów planszy, a naiwnie licząc, grę można rozegrać na 9! sposobów. Dzięki tam mocnemu uproszczeniu istnieje tu strategia optymalna, gwarantująca w najgorszym wypadku remis:

Dla tej gry istnieje optymalna startegia tzn. w najgorszym przypadku zremisujemy.

1. Win: If the player has two in a row, they can place a third to get three in a row.
2. Block: If the opponent has two in a row, the player must play the third themselves to block the opponent.
3. Fork: Cause a scenario where the player has two ways to win (two non-blocked lines of 2).
4. Blocking an opponent's fork: If there is only one possible fork for the opponent, the player should block it. Otherwise, the player should block all forks in any way that simultaneously allows them to make two in a row. Otherwise, the player should make a two in a row to force the opponent into defending, as long as it does not result in them producing a fork. For example, if "X" has two opposite corners and "O" has the center, "O" must not play a corner move to win. (Playing a corner move in this scenario produces a fork for "X" to win.)
5. Center: A player marks the center. (If it is the first move of the game, playing a corner move gives the second player more opportunities to make a mistake and may therefore be the better choice; however, it makes no difference between perfect players.)
6. Opposite corner: If the opponent is in the corner, the player plays the opposite corner.
7. Empty corner: The player plays in a corner square.
8. Empty side: The player plays in a middle square on any of the four sides.

Implementacja takiego bota byłaby jednak niezbyt ciekawa, a na dodatek specyficzna tylko dla tego konkretnego problemu. Dlatego my zajmiemy się eksploracją drzewa gry, a więc możliwych stanów oraz przejść między nimi. Na dobry początek ulepszymy naszego losowego bota trywialną heurystyką - jeżeli to możliwe, ma wybrać ruch wygrywający, a jeżeli nie, to losowy.

Można by też zadać pytanie, czemu nie wykorzystamy tutaj ciekawszego problemu, jak np. szachy. Odpowiedź jest prosta - nie mamy na to czasu, a konkretnie wieczności. Shannon obliczył dolną granicę złożoności drzewa gry na 10^{120}.

3.1 Wygraj, jeśli to możliwe w kolejnym kroku

3.1.1 Zadanie 1 (0.5 punkt)

Zaimplementuj ulepszonego losowego bota tak, aby wybierał ruch wygrywający, jeżeli to możliwe, a jeżeli nie, to losowy.

[10]:
```
import copy


class RandomPlayerWinIfCan(RandomPlayer):
    def move(self, board, player):
        res = self._get_winning_move(board, player)

        while res is None:
            row = random.randint(0, 2)
            col = random.randint(0, 2)
            if board[row][col] == 0:
                res = row, col

        row, col = res
        board[row][col] = player

    def _get_winning_move(self, board, player):
        for row in range(3):
            for col in range(3):
                empty = board[row][col] == 0
                horizontal = board[row][(col+1)%3] == board[row][col-1] ==␣
 ↪player
                vertical = board[(row+1)%3][col] == board[row-1][col] == player
                diagonal_htl = row == col and board[(row+1)%3][(col+1)%3] ==␣
 ↪board[row-1][col-1] == player
                diagonal_lth = row == 2-col and board[(row+1)%3][col-1] ==␣
 ↪board[row-1][(col+1)%3] == player

                if empty and (horizontal or vertical or diagonal_htl or␣
 ↪diagonal_lth):
                    return row, col

        return None
```

[12]:
```
game = TicTacToe(RandomPlayerWinIfCan(), RandomPlayer(), SIZE)
game.play()
```

```
---------------
|   ||   ||   |
---------------
|   ||   ||   |
---------------
|   ||   ||   |
---------------
```

```
---------------
|   ||   || O |
---------------
|   ||   ||   |
---------------
|   ||   ||   |
---------------
```

```
---------------
|   || X || O |
---------------
|   ||   ||   |
---------------
|   ||   ||   |
---------------
```

```
---------------
| O || X || O |
---------------
|   ||   ||   |
---------------
|   ||   ||   |
---------------
```

```
---------------
| O || X || O |
---------------
| X ||   ||   |
---------------
|   ||   ||   |
---------------
```

```
---------------
| O || X || O |
---------------
| X ||   || O |
---------------
|   ||   ||   |
---------------
```

```
---------------
| O || X || O |
---------------
| X ||   || O |
---------------
|   || X ||   |
---------------

---------------
| O || X || O |
---------------
| X ||   || O |
---------------
|   || X || O |
---------------
player 1 wins
```

[12]:
```
'win'
```

3.2 Blokuj kolejny krok wygrywający przeciwnika

Skoro w poprzednim zadaniu wygrywamy, kiedy możemy to zrobić w jednym kroku, to spróbujmy ulepszyć naszą strategię wcześniej. Możemy to zrobić, minimalizując swoje straty, czyli sprawdzamy dodatkowo, czy przeciwnik może skończyć grę. Jeżeli tak, to go blokujemy.

3.2.1 Zadanie 2 (0.5 punkt)

Zaimplementuj ulepszenie bota, w którym dodatkowo jeżeli nie możemy wygrać w danym ruchu, a przeciwnik tak, to go blokujemy. A jeżeli ani my, ani przeciwnik nie może wygrać w kolejnym ruchu, to wykonujemy losowe posunięcie.

[13]:
```
class Blocking(RandomPlayerWinIfCan):
    def move(self, board, player):
        res = self._get_winning_move(board, player)
        if res is None: res = self._get_winning_move(board, -player)

        while res is None:
            row = random.randint(0, 2)
            col = random.randint(0, 2)
            if board[row][col] == 0:
                res = row, col

        row, col = res
        board[row][col] = player
```

[18]:
```
game = TicTacToe(RandomPlayerWinIfCan(), Blocking(), SIZE)
game.play()
```

```
---------------
|   ||   ||   |
---------------
|   ||   ||   |
---------------
|   ||   ||   |
---------------
```

```
---------------
| O ||   ||   |
---------------
|   ||   ||   |
---------------
|   ||   ||   |
---------------
```

```
---------------
| O ||   ||   |
---------------
|   ||   || X |
---------------
|   ||   ||   |
---------------
```

```
---------------
| O || O ||   |
---------------
|   ||   || X |
---------------
|   ||   ||   |
---------------
```

```
---------------
| O || O || X |
---------------
|   ||   || X |
---------------
|   ||   ||   |
---------------
```

```
---------------
| O || O || X |
---------------
|   ||   || X |
---------------
| O ||   ||   |
---------------
```

```
---------------
| O || O || X |
---------------
|   ||   || X |
---------------
| O ||   || X |
---------------
player 2 wins
```

[18]: 'loss'

4 Algorytm minimax

Zaiplemetujemy teraz algorytm minimax. Minimalizuje on nasze maksymalne straty lub maksymalizuje minimalne zyski (maksmin). Poprzednie 2 kroki nas do tego zbliżały. Algorytm wywodzi się z teorii gier o sumie zerowej (gdzie wygrana ma wartość 1, przegrana -1, a remis 0 - w takich grach wygrana jednego gracza, oznacza, że drugi gracz przegrał, czyli nie ma strategii, która prowadziłaby do sytuacji *win-win*).

Twierdzenie o minimaksie (minimax theorem) mówi, że dla każdej gry dwuosobowej gry o sumie zerowej istnieje wartość V i mieszana strategia dla każdego gracza, takie, że:

- biorąc pod uwagę strategię gracza drugiego, najlepszą możliwą spłatą dla gracza pierwszego jest V,
- biorąc pod uwagę strategię gracza pierwszego, najlepszą możliwą spłatą dla gracza drugiego jest -V.

Każdy gracz minimalizuje maksymalną możliwą spłatę dla swojego przeciwnika – ponieważ gra jest grą o sumie zerowej, wynikiem tego algorytmu jest również maksymalizowanie swojej minimalnej spłaty.

Powyższa ilustracja przedstawia fragment analizy końcowej partii gry w kółko i krzyżyk. **Max** oznacza turę, w której gracz wybiera ten spośród dostępnych ruchów, który da maksymalną spłatę, natomiast **min** oznacza turę, w której gracz wybiera ruch, który da minimalną spłatę. Inaczej - *max* to ruch, z punktu wiedzenia gracza, dla którego chcemy, żeby wygrał, a *min* ruch gracza, który chcemy żeby przegrał.

Minimax jest algorytem rekurencyjnym, w którym liście drzewa możliwych ruchów oznaczają zakończenie gry, z przypisaną do nich wartością z punktu wiedzenia gracza, którego ruch jest w korzeniu drzewa możliwych ruchów. We wcześniejszych węzłach - w zależności czy jest tura gracza max, czy min, będą wybierane te gałęzie, które maksymalizują, bądź minimalizują wartość spłaty.

Przykładowo - w pierwszym wierszu mamy trzy strzałki i gracza *max*, dlatego gracz ten wybierze pierwszy możliwy ruch, bo daje on maksymalną spłatę. W drugim wierwszu w środkowej kolumnie mamy dwie strzałki. Gracz *min* wybierze zatem strzałkę (ruch) prawy, ponieważ minimalizuje on spłatę (0). Analogicznie w drugim wierszu po prawej stronie wybierana jest prawa strzałka, ponieważ daje ona wartość mimalną (-1).

Poniższy diagram zawiera to samo drzewo analizy ruchów, gdzie pozostawiono wyłącznie wartości spłaty dla poszczególnych węzłów.

Algorytm *minimax* jest następujący: 1. zainicalizuj wartość na $-\infty$ dla gracza którego spłata jest maksymalizowana i na $+\infty$ dla gracza którego spłata jest minimalizowana, 2. sprawdź czy gra się nie skończyła, jeżeli tak to ewaluuj stan gry z punktu widzenia gracza maksymalizującego i zwróć wynik, 3. dla każdego możliwego ruchu każdego z graczy wywołaj rekurencyjnie *minimax*: 1. przy maksymalizacji wyniku, zwiększ wynik, jeśli otrzymany wynik jest większy od dotychczas największego wyniku, 2. przy minimalizacji wyniku, pomniejsz wynik, jeśli otrzymany wynik jest mniejszy od dotychczas najmniejszego wyniku, 3. zwróć najlepszy wynik.

Algorytm ten wymaga dodatkowo funkcji ewaluującej, która oceni stan gry na końcu. Uznajemy, że zwycięstwo to +1, przegrana -1, a remis 0.

4.1 Zadanie 3 (2 punkty)

Zaimplementuj gracza realizującego algorytm minimaks.

[19]:
```
from math import inf

def check_board_full(board):
        for i in range(3):
            for j in range(3):
                if board[i][j] == 0: return False
        return True

def check_board_empty(board):
    for i in range(3):
        for j in range(3):
            if board[i][j] != 0: return False
    return True

class MinimaxPlayer(PlayerInterface):
    def move(self, board, player):
        if check_board_empty(board):
            board[1][1] = player
            return

        _, move = self._minimax(board, player, 1)

        row, col = move
        board[row][col] = player

    def _minimax(self, board, player, factor):
        # if factor is 1: maximizing, if it's -1: minimizing
        res = self._get_finished_value(board, factor * player)
```

```
        if res is not None: return res, None

        best_val = -inf * factor
        best_move = None

        for row in range(3):
            for col in range(3):
                if board[row][col] == 0:
                    board[row][col] = player
                    val, _ = self._minimax(board, -player, -factor)
                    if factor * val > factor * best_val:
                        best_val = val
                        best_move = row, col
                    board[row][col] = 0

        return best_val, best_move

    def _get_finished_value(self, board, player):
        if check_for_end(board, player): return 1
        if check_for_end(board, -player): return -1
        if check_board_full(board): return 0
        return None
```

[24]:
```
%%time
game = TicTacToe(MinimaxPlayer(), Blocking(), SIZE)
game.play()
```

```
---------------
|   ||   ||   |
---------------
|   ||   ||   |
---------------
|   ||   ||   |
---------------

---------------
|   ||   ||   |
---------------
|   || O ||   |
---------------
|   ||   ||   |
---------------

---------------
|   || X ||   |
---------------
```

```
|   || O ||   |
---------------
|   ||   ||   |
---------------

---------------
| O || X ||   |
---------------
|   || O ||   |
---------------
|   ||   ||   |
---------------

---------------
| O || X ||   |
---------------
|   || O ||   |
---------------
|   ||   || X |
---------------

---------------
| O || X ||   |
---------------
| O || O ||   |
---------------
|   ||   || X |
---------------

---------------
| O || X ||   |
---------------
| O || O || X |
---------------
|   ||   || X |
---------------

---------------
| O || X ||   |
---------------
| O || O || X |
---------------
| O ||   || X |
---------------
player 1 wins
CPU times: user 73 ms, sys: 5.6 ms, total: 78.6 ms
Wall time: 77 ms
```

[24]: 'win'

Wróć na chwilę do implementacji minimaxu i zastanów się, co się dzieje, jeżeli ten algorytm wykonuje ruch na pustej planszy i jak to wpływa na jego czas działania. Może coś można poprawić?

5 Alpha-beta pruning

Widzimy, że nasz poprzedni gracz jest właściwie idealny, bo w końcu sprawdza całe drzewo gry. Ma tylko w związku z tym wadę - dla większości problemów wykonuje się wieczność. Dlatego też zastosujemy ważne ulepszenie algorytmu minimax, nazywane alfa-beta pruning.

W przypadku klasycznego minimaxu ewaluujemy każdą możliwą ścieżkę gry. Alfa-beta pruning, jak i wiele innych metod, opiera się na "przycinaniu" drzewa, czyli nie ewaluujemy tych odnóg drzewa, co do których wiemy, że nie da ona lepszego wyniku niż najlepszy obecny. W niektórych wypadkach, np. w dobrej implementacji dla szachów, potrafi zredukować liczbę rozważanych ścieżek nawet o 99.8%.

Do poprzedniego algorytmu dodajemy 2 zmienne, α i β:

- α przechowuje najlepszą wartość dla gracza maksymalizującego swój wynik,
- β przechowuje najlepszą wartość dla gracza minimalizującego swój wynik.

Dzięki tej informacji możemy przerwać sprawdzanie danej gałęzi, kiedy α jest większa od β. Oznacza to bowiem sytuację, w której najlepszy wynik gracza maksymalizującego jest większy niż najlepszy wynik gracza minimalizującego.

Pseudokod:

```
function alphabeta(node, depth,  ,  , maximizingPlayer) is
    if depth = 0 or node is a terminal node then
        return the heuristic value of node
    if maximizingPlayer then
        value := −ϖ
        for each child of node do
            value := max(value, alphabeta(child, depth − 1,  ,  , FALSE))
              := max( , value)
            if      then
                break (*   cutoff *)

        return value
    else
        value := +ϖ
        for each child of node do
            value := min(value, alphabeta(child, depth − 1,  ,  , TRUE))
              := min( , value)
            if      then
                break (*   cutoff *)
        return value
```

5.1 Zadanie 4 (2 punkty)

Zaimplementuj gracza realizującego algorytm alfa-beta pruning, zmodyfikuj funkcje ewaluacji tak by preferowała szybkie zwycięstwo i penalizowała szybką porażkę.

[25]:
```
class AlphaBetaPlayer(MinimaxPlayer):
    def move(self, board, player):
        if check_board_empty(board):
            board[1][1] = player
            return

        _, move = self._alphabeta(board, player, 1, -float("inf"), float("inf"))

        row, col = move
        board[row][col] = player

    def _alphabeta(self, board, player, factor, alpha, beta):
        # if factor is 1: maximizing, if it's -1: minimizing
        res = self._get_finished_value(board, factor * player)
        if res is not None: return res, None

        best_val = -float("inf") * factor
        best_move = None

        for row in range(3):
            for col in range(3):
                if board[row][col] == 0:
                    board[row][col] = player
                    val, _ = self._minimax(board, -player, -factor)
                    if factor == 1: alpha = max(alpha, val)
                    else: beta = min(beta, val)
                    if alpha >= beta: return val, row, col
                    if factor * val > factor * best_val:
                        best_val = val
                        best_move = row, col
                    board[row][col] = 0

        return best_val, best_move
```

[30]:
```
%%time
game = TicTacToe(AlphaBetaPlayer(), MinimaxPlayer(), SIZE)
game.play()
```

```
---------------
|   ||   ||   |
---------------
|   ||   ||   |
```

```
--------------
|   ||   ||   |
--------------

--------------
|   ||   ||   |
--------------
|   || O ||   |
--------------
|   ||   ||   |
--------------

--------------
| X ||   ||   |
--------------
|   || O ||   |
--------------
|   ||   ||   |
--------------

--------------
| X || O ||   |
--------------
|   || O ||   |
--------------
|   ||   ||   |
--------------

--------------
| X || O ||   |
--------------
|   || O ||   |
--------------
|   || X ||   |
--------------

--------------
| X || O ||   |
--------------
| O || O ||   |
--------------
|   || X ||   |
--------------

--------------
| X || O ||   |
--------------
| O || O || X |
```

```
---------------
|   || X ||   |
---------------

---------------
| X || O || O |
---------------
| O || O || X |
---------------
|   || X ||   |
---------------

---------------
| X || O || O |
---------------
| O || O || X |
---------------
| X || X ||   |
---------------

---------------
| X || O || O |
---------------
| O || O || X |
---------------
| X || X || O |
---------------
draw
CPU times: user 518 ms, sys: 1.23 ms, total: 519 ms
Wall time: 520 ms
```

[30]:
```
'draw'
```

6 Monte Carlo Tree Search (MCTS)

Metody Monte Carlo polegają na wprowadzeniu losowości i przybliżaniu za jej pomocą rozwiązań dla trudnych problemów. Dla gry w kółko i krzyżyk nie jest to co prawda niezbędne, ale dla bardziej skomplikowanych gier, jak szachy czy go, już zdecydowanie tak.

Ogólna metoda MCTS składa się z 4 etapów: * selekcji - wybieramy najlepsze dziecko, aż dotrzemy do liścia, * ekspansji - jeżeli nie możemy dokonać selekcji, rozwijamy drzewo we wszystkich możliwych kierunkach z węzła, * symulacji - po ekspansji wybieramy węzeł do przeprowadzenia symulacji gry aż do końca, * wstecznej propagacji - kiedy dotrzemy do końca, ewaluujemy wynik gry i propagujemy go w górę drzewa.

W naszym wypadku wystarczy nieco prostszy algorytm Pure Monte Carlo Tree Search (Pure MCTS), w którym realizujemy tylko symulację i wsteczną propagację. Dla każdego możliwego ruchu w danej rundzie przeprowadzamy N symulacji oraz obliczamy prawdopodobieństwo

zwycięstwa/remisu/przegranej dla każdego z możliwych ruchów, a następnie wybieramy najlepszy ruch.

6.1 Zadanie 5 (2 punkty)

Zaimplementuj gracza realizującego algorytm Pure MCTS.

[31]:
```
from copy import deepcopy

class MonteCarloPlayer(PlayerInterface):
    def move(self, board, player):
        best_num_of_wins = 0
        best_move = None
        num_of_simulations = 100

        for row in range(3):
          for col in range(3):
              if board[row][col] == 0:
                  board[row][col] = player
                  num_of_wins = 0

                  for _ in range(num_of_simulations):
                      num_of_wins += self._simulate_game(deepcopy(board),␣
 ↪player)

                  if num_of_wins >= best_num_of_wins:
                      best_num_of_wins = num_of_wins
                      best_move = row, col

                  board[row][col] = 0

        row, col = best_move
        board[row][col] = player

    def _simulate_game(self, board, player):
        og_player = player
        while not check_board_full(board):
            player = -player
            while True:
                row = random.randint(0, 2)
                col = random.randint(0, 2)
                if board[row][col] == 0:
                    board[row][col] = player
                    break

            res = check_for_end(board, og_player)
            if res: return 1
            res = check_for_end(board, -og_player)
```

```
            if res: return 0

        return 0
```

[38]:
```
%%time
game = TicTacToe(MonteCarloPlayer(), MinimaxPlayer(), SIZE)
game.play()
```

```
---------------
|   ||   ||   |
---------------
|   ||   ||   |
---------------
|   ||   ||   |
---------------

---------------
|   ||   ||   |
---------------
|   || O ||   |
---------------
|   ||   ||   |
---------------

---------------
| X ||   ||   |
---------------
|   || O ||   |
---------------
|   ||   ||   |
---------------

---------------
| X ||   ||   |
---------------
|   || O ||   |
---------------
| O ||   ||   |
---------------

---------------
| X ||   || X |
---------------
|   || O ||   |
---------------
| O ||   ||   |
```

```
---------------

---------------
| X || O || X |
---------------
|   || O ||   |
---------------
| O ||   ||   |
---------------

---------------
| X || O || X |
---------------
|   || O ||   |
---------------
| O || X ||   |
---------------

---------------
| X || O || X |
---------------
|   || O || O |
---------------
| O || X ||   |
---------------

---------------
| X || O || X |
---------------
| X || O || O |
---------------
| O || X ||   |
---------------

---------------
| X || O || X |
---------------
| X || O || O |
---------------
| O || X || O |
---------------
draw
CPU times: user 660 ms, sys: 21.2 ms, total: 681 ms
Wall time: 674 ms
```

[38]: 'draw'

7 Turniej

Teraz przeprowadzimy turniej w celu porównania zaimplementowanych metod. Każdy algorytm będzie grał z każdym po 10 razy.

NIE WYKONANIE TURNIEJU SKUTKUJE OTRZYMANIEM ZERA PUNKTÓW ZA ZADANIE

[39]:
```
from collections import defaultdict
from IPython.display import display
import pandas as pd


def print_scores(scores, names):
    win = {}
    for name in names:
        win[name] = [scores["win"][name][n] for n in names]
    loss = {}
    for name in names:
        loss[name] = [scores["loss"][name][n] for n in names]
    draw = {}
    for name in names:
        draw[name] = [scores["draw"][name][n] for n in names]

    df = pd.DataFrame.from_dict(win, orient="index", columns=names)
    display(df)
    df2 = pd.DataFrame.from_dict(loss, orient="index", columns=names)
    display(df2)
    df3 = pd.DataFrame.from_dict(draw, orient="index", columns=names)
    display(df3)
```

[40]:
```
%%time

number_of_rounds = 10
players = [
    RandomPlayer(),
    Blocking(),
    RandomPlayerWinIfCan(),
    MinimaxPlayer(),
    AlphaBetaPlayer(),
    MonteCarloPlayer(),
]
scores = defaultdict(lambda: defaultdict(lambda: defaultdict(int)))

for player in players:
    for adversary in players:
        for i in range(number_of_rounds):
            game = TicTacToe(player, adversary, SIZE)
```

```
            score = game.play(False)
            # print("player name {} adversary name {} score {} ".format(player.
 ↪name, adversary.name, score))
            scores[score][player.name][adversary.name] += 1


print_scores(scores, [player.name for player in players])
```

```
                    RandomPlayer  Blocking  RandomPlayerWinIfCan  \
RandomPlayer                   6         1                     2
Blocking                       9         5                     9
RandomPlayerWinIfCan           5         3                     7
MinimaxPlayer                  9         6                    10
AlphaBetaPlayer               10         5                    10
MonteCarloPlayer              10         4                    10

                    MinimaxPlayer  AlphaBetaPlayer  MonteCarloPlayer
RandomPlayer                    0                0                 0
Blocking                        0                0                 9
RandomPlayerWinIfCan            0                0                 1
MinimaxPlayer                   0                0                10
AlphaBetaPlayer                 0                0                10
MonteCarloPlayer                0                0                 9
                    RandomPlayer  Blocking  RandomPlayerWinIfCan  \
RandomPlayer                   2         8                     8
Blocking                       0         1                     0
RandomPlayerWinIfCan           2         5                     3
MinimaxPlayer                  0         0                     0
AlphaBetaPlayer                0         0                     0
MonteCarloPlayer               0         1                     0

                    MinimaxPlayer  AlphaBetaPlayer  MonteCarloPlayer
RandomPlayer                    9                8                10
Blocking                        2                3                 1
RandomPlayerWinIfCan            7                6                 9
MinimaxPlayer                   0                0                 0
AlphaBetaPlayer                 0                0                 0
MonteCarloPlayer                2                4                 1
                    RandomPlayer  Blocking  RandomPlayerWinIfCan  \
RandomPlayer                   2         1                     0
Blocking                       1         4                     1
RandomPlayerWinIfCan           3         2                     0
MinimaxPlayer                  1         4                     0
AlphaBetaPlayer                0         5                     0
MonteCarloPlayer               0         5                     0
```

	MinimaxPlayer	AlphaBetaPlayer	MonteCarloPlayer
RandomPlayer	1	2	0
Blocking	8	7	0
RandomPlayerWinIfCan	3	4	0
MinimaxPlayer	10	10	0
AlphaBetaPlayer	10	10	0
MonteCarloPlayer	8	6	0

```
CPU times: user 1min 23s, sys: 831 ms, total: 1min 24s
Wall time: 1min 24s
```

8 Zadanie dodatkowe (2 punkty)

Rozwiń kod algorytmu MCTS tak, aby działał z ogólnymi zasadami, a nie w formie uproszczonego Pure MCTS.

Zastosuj prosty, ale bardzo skuteczny sposób selekcji UCT (*Upper Confidence Bound 1 applied to trees*), będący wariantem bardzo skutecznych metod UCB, stosowanych m.in. w podejmowaniu decyzji, uczeniu ze wzmocnieniem i systemach rekomendacyjnych. Polega na wyborze tego węzła, dla którego następujące wyrażenie ma maksymalną wartość:

$$\frac{w_i}{n_i} + c\sqrt{\frac{\ln N_i}{n_i}}$$

gdzie: * w_i to liczba zwycięstw dla węzła po rozważeniu i-tego ruchu * n_i to łączna liczba symulacji przeprowadzonych dla węzła po i-tym ruchu, * N_i oznacza całkowitą liczbę symulacji przeprowadzoną po i-tym ruchu dla węzła-rodzica aktualnie rozważanego węzła, * c to hiperparametr, wedle teorii powinien mieć wartość $\sqrt{2}$.

O uzasadnieniu tego wzoru możesz więcej przeczytać tutaj.

Jeżeli chcesz, możesz zastosować ten algorytm dla bardziej skomplikowanej gry, jak np. warcaby czy szachy.

[45]:
```python
import random
import math
from copy import deepcopy

class MonteCarloPlayer(PlayerInterface):
    def move(self, board, player):
        root = Node(board, player)
        num_simulations = 100

        for _ in range(num_simulations):
            node = self._select_node(root)
            result = self._simulate(node)
            self._backpropagate(node, result)

        best_move = self._select_best_move(root)
```

```
        row, col = best_move
        board[row][col] = player

    def _select_node(self, node):
        while not node.is_terminal() and node.is_fully_expanded():
            node = self._select_best_child(node)
        if not node.is_terminal():
            return self._expand(node)
        return node

    def _select_best_child(self, node):
        exploration_constant = math.sqrt(2)
        children = node.children.values()
        log_total_simulations = math.log(sum(child.num_simulations for child in␣
↪children))
        best_child = max(children, key=lambda child: child.num_wins / child.
↪num_simulations +
                                                     exploration_constant * math.
↪sqrt(log_total_simulations / child.num_simulations))
        return best_child

    def _expand(self, node):
        unexplored_moves = [(row, col) for row in range(3) for col in range(3)␣
↪if (row, col) not in node.children]
        random_move = random.choice(unexplored_moves)
        new_board = deepcopy(node.board)
        new_board[random_move[0]][random_move[1]] = node.player
        new_node = Node(new_board, -node.player)
        node.children[random_move] = new_node
        return new_node

    def _simulate(self, node):
        board = deepcopy(node.board)
        player = node.player
        while not check_board_full(board):
            player = -player
            available_moves = [(row, col) for row in range(3) for col in␣
↪range(3) if board[row][col] == 0]
            random_move = random.choice(available_moves)
            board[random_move[0]][random_move[1]] = player

            result = check_for_end(board, node.player)
            if result is not None:
                return result

        return 0.5  # Draw
```

```
    def _backpropagate(self, node, result):
        while node is not None:
            node.num_simulations += 1
            node.num_wins += result if node.player == 1 else (1 - result)
            node = node.parent

    def _select_best_move(self, root):
        children = root.children.values()
        best_child = max(children, key=lambda child: child.num_simulations)
        return best_child.move


class Node:
    def __init__(self, board, player, parent=None):
        self.board = board
        self.player = player
        self.parent = parent
        self.children = {}
        self.num_simulations = 0
        self.num_wins = 0

    def is_terminal(self):
        return check_for_end(self.board, self.player) is not None or␣
 ↪check_board_full(self.board)

    def is_fully_expanded(self):
        return all(child in self.children for child in self.
 ↪_get_possible_moves())

    def _get_possible_moves(self):
        return [(row, col) for row in range(3) for col in range(3) if self.
 ↪board[row][col] == 0]
```